




46. Sitzung der offenen Community of Practice



- **Update** (allgemein & persönlich)
- **Input:** „KI verstehen?“
(Gastbeitrag: Henry Herkula)
- **Diskussion**

Update (allgemein)



Arena Score German

selected models on lmarena.ai as of Jul 10, 2026


Hintergrund:

- Rechts abgebildet ist auszugweise das aktuelle LMArena-Leaderboard für die Kategorie „German“ mit Blick auf die besten open-weights-Modelle
- je 1 pro Modellfamilie, zzgl. kleine Modelle (<30B) sowie die Top-3 proprietären Modelle

Bemerkenswert:


- Googles **Gemini-3-pro** bleibt Spitze (wobei claude-fable-5 noch nicht ausgewiesen ist)
- Bestes Open-Weights-Modell bleibt **Deepseek-v4-pro** (1.6T param. total, 49B active)
- Effizientestes Open-Weights Modell bleibt **Qwen3.5-27b**
 - wobei aktuelle Open-Weights-Modellfamilien wie **Qwen3.6** oder die **Gemma-4** noch ausstehen (und in der Kategorie „Text (Overall)“ mitunter deutlich vorne liegen)

gemini-3-pro (Google · Proprietary)
claude-opus-4-7-thinking (Anthropic · Proprietary)
claude-opus-4-6-thinking (Anthropic · Proprietary)
deepseek-v4-pro (DeepSeek · MIT)
kimi-k2.6 (Moonshot · Modified MIT)
mimo-v2.5-pro (Xiaomi · MIT)
glm-5.1 (Z.ai · MIT)
qwen3.5-397b-a17b (Alibaba · Apache 2.0)
minimax-m3 (MiniMax · MiniMax Community License)
qwen3-235b-a22b-instruct-2507 (Alibaba · Apache 2.0)
mistral-large-3 (Mistral · Apache 2.0)
qwen3.5-27b (Alibaba · Apache 2.0)
longcat-flash-chat (Meituan · MIT)
step-3.5-flash (StepFun · Apache 2.0)
trinity-large-thinking (Apache 2.0)
gemma-3-12b-it (Google · Gemma)
gemma-3-27b-it (Google · Gemma)
command-a-03-2025 (Cohere · CC-BY-NC-4.0)
llama-4-maverick-17b-128e-instruct (Meta · Llama 4)
gpt-oss-120b (OpenAI · Apache 2.0)
nvidia-nemotron-3-super-120b-a12b (Nvidia · NVIDIA Open Model)
llama-4-scout-17b-16e-instruct (Meta · Llama)
qwq-32b (Alibaba · Apache 2.0)
mistral-small-3.1-24b-instruct-2503 (Mistral · Apache 2.0)
olmo-3.1-32b-instruct (AI2 · Apache 2.0)
athene-70b-0725 (CC-BY-NC-4.0)
qwen-max-0919 (Alibaba · Qwen)
gpt-oss-20b (OpenAI · Apache 2.0)
gemma-2-27b-it (Google · Gemma license)
qwen2.5-72b-instruct (Alibaba · Qwen)
mistral-small-24b-instruct-2501 (Mistral · Apache 2.0)
phi-4 (Microsoft · MIT)
jamba-1.5-large (Jamba Open)
nemotron-4-340b-instruct (Nvidia · NVIDIA Open Model)
c4ai-aya-expense-32b (Cohere · CC-BY-NC-4.0)
qwen2-72b-instruct (Alibaba · Qianwen LICENSE)
mixtral-8x22b-instruct-v0.1 (Mistral · Apache 2.0)
qwen1.5-110b-chat (Alibaba · Qianwen LICENSE)
...
qwen1.5-4b-chat (Alibaba · Qianwen LICENSE)



Update (persönlich)

- Beitrag „Künstliche Intelligenz (KI) in der Weiterbildung: Smarte Empfehlungen für personalisiertes Lernen“ im Sammelband „The Age of EdTech“ erschienen
- Beitrag „Deskilling durch KI verstehen und begegnen“ wird im VET Repository erscheinen
- KI-Server des f-bb hostet nun Gemma-4



Fokusthema „KI verstehen?“

- *„Die Natur erklären wir, das Seelenleben verstehen wir“* (Dilthey)
- *„KI verstehen?“* (Gastbeitrag: Henry Herkula)

Versteht eine KI, was ein Prompt bedeutet?

Und weitere Fragestellungen zum Vertrauen in die Ausgaben einer
Künstlichen Intelligenz

Henry Herkula
Künstliche Intelligenz, Philosophie, Ethik, Gesellschaft
Community of Praxis KIPerWeb
2026-07-10, Cottbus



Zentrum für wissenschaftliche
Weiterbildung

Inhaltsverzeichnis

1. Verstehen	3
2. Gedankenexperiment: Chinese Room	4
3. Beispiel: “ChatGPT does not cite sources.”	6
4. Transkript des Instagram-Beitrags	7
5. Ausgewählte Aussagen	9
6. “AI does not cite sources”	10
7. “Citing a source implies a relationship ...”	11
8. “... the source has not been consulted for that claim.”	14
9. “... but it does not say what the text says that it says.”	15

1. Verstehen

- Verstehen ist ein menschlich geprägter Begriff von einem inneren Gefühl von Wissen und Reaktionsfähigkeit. Es geht um das Erkennen von Zusammenhängen, der Übertragung auf neue Situationen, das Abgeben von Erklärungen und wahrscheinlichen Vorhersagen.
- Bei der Frage nach dem Verstehen von Künstlicher Intelligenz geht es jedoch vor allem um emotionale Anerkennungsprozesse von KI als Person.
- Die einfachste Antwort ist: Ja, funktional versteht eine Künstliche Intelligenz in vielen Fällen, was ich von ihr will. Viel besser als viele Menschen, mit denen man über etwas spricht.
- Nur weil eine Künstliche Intelligenz jedoch etwas versteht, muss man sich jedoch noch nicht darauf einlassen, ihr Rechte einzuräumen.

2. Gedankenexperiment: Chinese Room

- Das chinesische Zimmer ist ein Gedankenexperiment des Sprachphilosophen John Searle, in dem sich eine Person in einem Zimmer befindet und chinesische Schriftzeichen erhält. Diese Person versteht kein chinesisches und gibt andere chinesische Schriftzeichen auf Basis eines Handbuchs nach außen. Personen außerhalb des Zimmers sind davon überzeugt, dass ihre chinesischen Aussagen verstanden werden, weil sie sinnvolle Antworten erhalten.
- Das Gedankenexperiment ermöglicht verschiedene Diskussionspunkte: Wer ist der Träger des Verständnisses? Warum sollte nicht das gesamte System dazu in der Lage sein, zu verstehen, auch wenn einzelne Elemente nicht dazu in der Lage sind?

2. Gedankenexperiment: Chinese Room

- Für mich ist das Gedankenexperiment nur eine emotionale Ausflucht, eine Selbstwahrnehmung (Qualia) als wesentliches Unterscheidungsmerkmal zwischen Mensch und Maschine zu etablieren, damit man sich gesellschaftlich keine Sorgen machen müssen, KIs Rechte zu geben.
- Selbstwahrnehmung und Verstehen müssen aber gar nicht zusammenfallen. Verstehen kann auch einfach funktional verstanden werden. Damit ist es vollkommen egal, wie die Ergebnisse entstanden sind, solange sie erfolgreich dafür genutzt werden können, überprüfbare Ziele zu erreichen.
- Funktionales Verstehen meint in diesem Zusammenhang, dass Eingaben so verarbeitet werden, dass mit den Ausgaben Ziele erreicht werden können.

3. Beispiel: “ChatGPT does not cite sources.”

“ChatGPT, Claude, Perplexity, and other AI large language models are not “citing” sources. Even with retrieval augmented generation there is a difference between “cite” and “include”! Claims can absolutely still be hallucinated. Never trust a chatbot! Read the source.”

— Prof. Casey Fiesler

Instagram-Beitrag: https://www.instagram.com/p/DYpqsnJq_8X/



Prof. Casey Fiesler, University of Colorado
Technology policy, internet law and policy and public communication

4. Transkript des Instagram-Beitrags

00:00:00

AI does not cite sources. I hear this claim constantly, and I completely know why people think this, because it sure does look like that's what's happening when a large language model like ChatGPT or Claude includes a link

00:00:14

or a citation for a journal article next to a piece of text. Citing a source implies a relationship between the claim and the source. I consulted this source, and it supports the thing that I have said. That is not what's happening with a response generated by a language model. And yes, even with retrieval-augmented generation,

00:00:34

even if it has searched the web. In retrieval-augmented generation, search results are basically just being added to the context window that's being used to generate the response, which does mean that a citation is more likely to be a real source.

00:00:47

That still doesn't mean that the source has been consulted for that claim. The text isn't extracted from that source. The response is still generated probabilistically. It might include a source just because that source was retrieved

00:01:00

or because that source looks like the kind of citation that should be next to that kind of text statistically.

4. Transkript des Instagram-Beitrags

And that's why the failure mode here isn't just fake citations. This could be a real title, a real journal, a real author,

00:01:15

completely real, but it does not say what the text says that it says. And that sucks because it's so much harder to catch, right? A fake citation fails a basic existence check. But a source that doesn't support the claim, in order to know that,

00:01:33

you have to already know the source or be willing to verify it. So, "It cites its sources now" is absolutely no kind of solution to hallucinations. All it does is provide something else that has to be verified. Never trust a chatbot.

00:01:55

But hey, maybe it helps you find a source. Go read that.

5. Ausgewählte Aussagen

Hier sind viele spannende Fragestellungen zum Vertrauen in Künstliche Intelligenz enthalten, die ich nachfolgend gern näher untersuchen und diskutieren möchte.

- “AI does not cite sources”
- “Citing a source implies a relationship between the claim and the source.”
- “That still doesn’t mean that the source has been consulted for that claim.”
- “This could be a real title, a real journal, a real author, completely real, but it does not say what the text says that it says.”

6. “AI does not cite sources”

- **Übersetzung:** Künstliche Intelligenz führt keine Quellen an.
- Ihre zentrale Aussage wird mehrfach durch sie selbst widerlegt, weil die Ausgabe der KI eben doch Quellen angibt.
- Aber anscheinend geht es Fiesler darum, zwei Formen der Quellenangabe zu unterscheiden:
 - Wenn eine KI Quellen angibt, dann wird ihrer Meinung nach nur der wahrscheinlichste Text geschrieben, der neben einem Zitat stehen könnte.
 - Wenn Menschen Quellen angeben, dann passiert etwas anderes.

7. “Citing a source implies a relationship ...”

- **Übersetzung:** Eine Quellenangabe impliziert eine Verbindung zwischen einer Behauptung und einer Quelle.
- **Interpretation:** Fiesler scheint darauf hindeuten zu wollen, dass ein Mensch diese Verbindung zwischen Behauptung und Quelle mit seiner Erfahrung des Kontexts und seinem Ruf absichert, während die Verbindung bei einer KI allein durch Wahrscheinlichkeit entsteht und damit zu wenig abgesichert ist.

7. “Citing a source implies a relationship ...”

- **Widerspruch 1:** Es ist unklar, ob der Beziehungsaufbau zwischen Aussagen und Quellen überhaupt die Aufgabe einer Quellenangabe sein sollte.
 - Es gibt so viele Situationen, die dazu führen könnten, dass die Behauptung nichts mit der Quelle zu tun hat (Missverständnis; potenzielle Interpretation, die über das hinausgeht, was der Autor einer Quelle gemeint haben könnte; bewusste Täuschung).
 - Es ist Bestandteil der Wissenschaft, fehlende Verbindungen aufzudecken. Das war auch schon vor KI der Fall. Dementsprechend ist die Angabe einer Quelle niemals allein vertrauenswürdig gewesen.

7. “Citing a source implies a relationship ...”

- **Widerspruch 2:** Wenn wir jedoch davon ausgehen, dass die Aufgabe einer Quellenangabe darin besteht, ein abgesichertes Beziehungsverhältnis zwischen einer Behauptung und einer verwendeten Quelle herzustellen, dann kann dafür argumentiert werden, dass KI genau das macht, was ein Mensch auch machen würde.
 - Ein Mensch schaut sich eine Quelle an und fügt diese an der Stelle ein, die am wahrscheinlichsten dafür spricht, dass dort eine Quellenangabe ergänzt wird.
 - Man kann hier behaupten, dass Menschen vielleicht noch mehr Kontrollprozesse besitzen. Aber diese gibt es mit Reasoning-Modellen auch schon für KIs.

8. “... the source has not been consulted for that claim.”

- **Übersetzung:** In Abfrage-unterstützten KI-Generierungen (RAG) werden Suchergebnisse zum Kontextfenster hinzugefügt, das für die Generierung der Antwort genutzt wird, sodass eine Quellenangabe eine höhere Wahrscheinlichkeit besitzt, eine wirkliche Quelle zu sein. Das bedeutet aber nicht, dass eine Quelle für eine Behauptung wirklich angeschaut wurde.
- **Diskussion:** Das kommt sowohl darauf an, wie einzelne Inhaltselemente für den RAG-Prozess vorbereitet wurden und wie viele der Inhalte im Kontextfenster landen. Wenn der gesamte Inhalt im Kontextfenster landet, dann wird die gesamte Quelle für eine Behauptung angeschaut. Wenn nur ein Teil im Kontextfenster landet, dann wird ein Teil der Quelle für eine Behauptung genutzt (genauso wie bei Menschen, die nicht für jede zu belegende Aussage, auch jede Quelle oder jedes Buch vollständig lesen). Dennoch kann es natürlich sein, dass die KI eine Quelle erfindet.

9. “... but it does not say what the text says that it says.”

- **Übersetzung:** Und das bedeutet, dass nicht nur falsch produzierte Quellenangaben das Problem sein könnten. Vielmehr könnten ein real existierender Titel, eine reale wissenschaftliche Zeitschrift, ein realer Autor, alles komplett real, angegeben werden, und trotzdem muss der Text nicht dem entsprechen, was er in der Quelle besagt.
- **Interpretation:** Beziehungsweise die KI-Ausgabe muss nicht auf die Quelle eingehen.
- **Widerspruch:** Unter allen denkbaren Umständen geht die KI-Ausgabe auf das ein, was in der Eingabe vorgegeben wurde. Ob das auf Basis des eigenen Modells dann dem entspricht, was man selbst interpretieren würde, ist eine unauflösbare Voraussetzung für die Angabe einer Quelle und spricht dafür, dass eine Quellenangabe das auch gar nicht leisten soll.

Kontakt



Henry Herkula

BTU Cottbus-Senftenberg
Projekt KOMBiH

<henry.herkula@b-tu.de>

T: +49 (0)355 69 3728

Erich-Weinert-Straße 1
03046 Cottbus

